

读书笔记 · 摘编自公众号「黄华书房」2026-08-22

再次遇到大时代

AI 时代的十个判断：竞争格局 · 技术演进 · 泡沫与商业 · 华为的机会

原文与图表：黄华书房《再次遇到大时代》，2026 年 8 月 22 日夜，深圳

本胶片按原文顺序摘编，数字均取自原文及其图表；页脚注明各图来源



【竞争格局】科技竞争不只是技术竞争，也是地缘竞争和生存竞赛

一战/二战、海湾战争之后都是科技泉涌期；这一波军事变革的决定性力量是**智能化**



AGI 对应的是原子弹。看懂这一点，就看懂了美国为什么围堵、政府为什么不计成本地投。


【竞争格局】中美 AI 竞争的本质：打破技术垄断高价收割，解构 AGI 神话

全球被开发者商用调用、真实落地的基础模型里，中国模型占 65%—70%；开源落后闭源 3—6 个月，但定价和成本优势很大

走向技术平权，闭源领先 3—6 个月

排名	旗舰模型	所属企业	国家	说明
1	Claude Opus 5	Anthropic	美国	闭源，4 年投入 1290 亿美元
2	GPT-5.4 Pro	OpenAI	美国	闭源，4 年投入 1800 亿美元
3	Gemini 3.1 Ultra	Google DeepMind	美国	闭源，4 年投入 4400 亿美元
4	Llama 4 Ultra	Meta	美国	开源（商用授权）
5	豆包 4.0 Ultra	字节跳动	中国	闭源
6	Qwen 3.5 Max-Thinking	阿里	中国	开源
7	DeepSeek-V4 Pro	DeepSeek	中国	开源，投入 580 亿
8	MiMo-V2-Pro	小米集团	中国	开源
9	Grok 4.20 Ultra	SpaceX	美国	闭源
10	openPangu 2.0 Pro	华为	中国	开源
11	Mistral Large 3	Mistral AI	法国	开源
12	GLM-5 Ultra	智谱 AI	中国	开源，投入 376 亿
13	Kimi K2.6 Thinking	月之暗面	中国	开放权重，投入 376 亿
14	ERNIE 5.0 Ultra	百度	中国	开源
15	Phi-4 Ultra	Microsoft	美国	闭源，小型 Phi 系列开源
16	Spark Ultra 4.0	科大讯飞	中国	闭源
17	Hunyuan Ultra	腾讯	中国	闭源
18	Yi-Large 3.0	零一万物	中国	闭源，全系开源基座
19	Dolly Seed 2.0 Pro	Databricks	美国	闭源，基础 Dolly 开源
20	ABAB 6.5 Ultra	MiniMax	中国	闭源

御三家



美国头部公司 AI 投资是中国企业的几十倍，算力卡差十倍以上；蒸馏的本质是跟着老师最快地学。

DeepSeek 时刻 + DeepSeek 2.0 时刻（Kimi K3）的影响

底层原创 vs 工程优化（+蒸馏），谁先到 AGI


开源落后闭源 3—6 个月，价格却差一个量级。中国的打法是把 AI 应用层打到低价或免费，把利润逼到硬件上去。

【竞争格局】Token 两年降价 99%，智能走向电力化，杰文斯悖论把市场做大

AI 热点快速切换，迭代进步

AI 热点主题	峰点时间	热度周期
DeepSeek R1	2025.02	1.5 月
Manus	2025.03	1 月
Gemini 3.0	2025.05	2 月
SORA 2.0	2025.06	1.5 月
Agentic AI	2025.07	2 月
GPT-5	2025.08	1 月
AI Coding	2025.09	3 月
A2A / MCP	2025.11	1 月
Seedance 2.0	2026.02	1.5 月
龙虾 OpenClaw	2026.02	2 月+
Harness 工程	2026.03	3 月+
DeepSeek V4.0	2026.04	1 月+
Loop 工程	2026.06	1 月+


AI 推理价格降低 99% 用时 两年



每百万 Token 从 30 美元降至 0.1—2.5 美元

Source: BOND

杰文斯效应：全球日均消耗 260 万亿 Tokens/天



价格坍缩引爆总用量：企业 AI 云支出两年翻三倍

- 战略：把“模型的开放”和“AI 从数字世界走向物理世界”绑在一起。只要 AI 大脑变成免费商品，价值链的最高利润就会转移到互补品（物理硬件）上，削弱美国软件护城河。
- 中国的低成本模型是 Token 降价的主要力量，量大管饱、质量越来越好，美国用户也在转向。

Token 两年降 99%，产业没垮，用量反而暴涨。真正短缺的不是需求，是算力——按水电的用法，算力需求可能要涨一万倍。

【技术演进】AI 发展是阶跃式进步：无法清晰规划，能力边界无法预测

否定 → 怀疑 → 相信 → 超越预期

语音识别

机器视觉

下棋围棋

药物研究

NLP

吟诗作画

自动驾驶

做数学题

编程

AGI

第一代：符号 AI


1956 Dartmouth 会议
符号模型 / 规则模型 / 感知机
知识的可搜索性

第二代：感知智能

大数据驱动的统计学习方法
初步实现文本、图像、语音的感知与识别
知识的可计算性
代表：Amazon、字节跳动、Microsoft、海康威视
Google DeepMind、商汤、旷视、科大讯飞、云从、依图

第三代：认知智能

“认知”的可计算性
核心思路：数据统计与知识推理融合的计算
与脑认知机理融合的计算




AI 从“会做题”走向“会办事”：能被准确评估的领域基本都超过了人类，开放领域还有差距。AI 已经拿了两个诺贝尔奖。

堵了全球科学家十几年的 NLP 难题，被大模型一次解决。乐观的人不一定对，但他们是最有进化优势的力量。

【技术演进】智能体像孩子一样成长：从指令约束到闭环迭代，直到自主进化

智能体工程（Agentic Engineering）范式不断演化 圆上一行 = 孩子成长的比喻；虚线圆 = 还没发生




METR 定律：前沿 AI 智能体可稳定完成任务的时间大约每 7 个月翻一番。Agent 发展的挑战：安全、伦理、生态、算力、能源

多大模型能实现 AGI，还没法预测 圆大小 $\propto \log$ 总参数量；圆下为总参数量 / 激活参数

$$\text{智能} = -K + a \cdot \log(N) + B \cdot \log(D) + R \cdot \log(C)$$

N 模型参数 · D 训练数据量 · C 上下文长度



参照系：人脑与算力


参考人脑

突触 100-600T (生物权重，多维度参数)
神经元 86B | 当前最大模型 10T

马斯克 Terafab

每年生产 1TW 算力 $\approx$ 1000 个中型核电站，是全球已有核电站总数的一倍多

AGI 何时到：各家预测从 2026 排到 2040



预测的差别，简化讲就是数字智能与具身智能的差异

Agent 正在从提示词走向闭环自迭代。当 AI 能改进自己，就是奇点；AGI 何时到，分歧只在“数字智能”还是“具身智能”。

【技术演进】为什么从卷模型到卷 Coding Agent：它是加速 AGI 的核心引擎

Boris Cherny (Claude Code 负责人)：这不是小改进，相当于古腾堡印刷术诞生

Coding 表达万物

- 语言和代码都是对世界的高度浓缩抽象
- 语言是对世界的描述，Coding 是对 Solution 的描述
- 白领用电脑操作的绝大部分任务可自动化

Coding 是最重要的 AGI 加速器

- 从卷数学竞赛到卷代码，是智商的提升
- 长上下文、强关联和逻辑、可被验证
- 领先模型不重视 Coding，大概率会掉队

Coding 具备飞轮效益

- 像 Amazon 卖书：拉通仓储物流后，横向扩品类极容易
- AI Coding 不只是一个应用场景

为什么是
Coding Agent?

谷歌 / 马斯克 / OpenAI：谷歌 26 年 4 月组建 Strike Team，火速填补 AI Coding 差距，联合创始人布林亲自督战；SpaceX 用 600 亿期权收购 Cursor，接入 Colossus 超算，正面狙击 Coding 巨头；OpenAI GPT-5 系列非常强化 Coding

字节："2023 年预测到 2025 年简单工程 AI 代码贡献率 30%，复杂工程 10%。现在实际简单工程 90%，复杂工程 50%，技术发展速度远比我们之前预测的快。"

阿里："AI Coding 已经是阿里 CEO 的第一优先级目标"

红杉中国："Anthropic 没有边界，它是美国软件界的公敌"；"现在很像 2013—2014 年字节正在注册的时候"；"Coding 不局限于软件工程，是新的商业基石"

讲话 / 画画

奥数

软件大赛

科研?


资深程序员保守、先锋激进：像老登想把吃过的苦传给小登，小登觉得 AI 时代一切都变了，不想没苦硬吃

AI 编程是目前唯一真正盈利的 Agent，也是模型智商提升的引擎。领先模型不重视 Coding，大概率会掉队。

【泡沫与商业】AI 投资肯定有泡沫：投入-产出剪刀差，三派对同一组数据各有解读

过去 300 年，大建设的钱都是借来的：运河、铁路、电气化、电信、房地产。泡沫是科技进步的催化剂

投入-产出剪刀差（十亿美元，对数级差距）



注：2026 年五大厂商（亚马逊 / 谷歌 / Meta / 微软 / 甲骨文）capex 约 6900 亿美元，摩根士丹利 CEO Ted Pick 口径的全行业数据中心 capex 已上修至 ~8500 亿美元

≈ 7600 亿美元

AI 相关资本开支

占营收 36%

超过 2000 年互联网泡沫 32% 的峰值


2026 Q3

谷歌季报已现负现金流；预计领先云厂相继转负

各方关于数据的解读

破裂派 坚定看空	产业泡沫派 承认泡沫	非泡沫派 坚定看多
代表人物 Burry / 高盛 Covello	代表人物 Bezos / Altman / 鲍威尔	代表人物 黄仁勋 / 摩根士丹利 Wilson
定量锚点 MIT 95% 试点零 ROI；18—24 个月回报验证期已过	定量锚点 达利欧警告 2026 风险；Dimon 预警 20% 级回调	定量锚点 EPS 修正广度 24% 创 4 年新高；推理成本急降解锁需求
逻辑链 巨额投入 ↓ 回报缺席 ↓ 依赖旧粉饰 ↓ 估值 / 盈利双杀	逻辑链 技术真实 + 非理性溢价 ↓ 资本出清期 ↓ 赢家沉淀 / 基建留存	逻辑链 算力短缺 + 成本下降 ↓ 激发长尾需求 ↓ 盈利向全产业链扩散

一轮技术周期




从宏观看，全球经济持续恶化，没看到 AI 带来增量 GDP，反而挤压就业、拉低中产消费力；从企业看，AI 基础设施不是一次性修铁路，要不断换发动机。

泡沫是新技术落地的必经机制。问题不是有没有泡沫，是资本开支和变现节奏脱节了多远。

【泡沫与商业】AI 落地企业和物理世界有难以逾越的剪刀差；热潮的本质是资源虹吸杠杆

AI2B 价值落地，走向物理世界，存在 **难以逾越的剪刀差**

当前 AI 热潮的本质是 **地缘与资本驱动的资源虹吸杠杆**
是实现 AGI、进入 AI 超级周期，跟金融泡沫破灭的赛跑




AI2B 关键商业结构 =

$$\begin{aligned} & \text{客户侧} \frac{\text{场景价值}^2 \times \text{数字化程度} \times \text{人才准备度} \times \text{市场规模}}{\text{投资成本} \times \text{变革阻力}} \\ & \times \text{厂商侧} \frac{\text{产品能力}^2 \times \text{平台能力} \times \text{伙伴生态} \times \text{行业理解力}}{\text{集成难度} \times \text{成本} \times \text{复制难度}} \\ & \times \text{商业模式} \end{aligned}$$

- MIT: 95% 企业试点零 ROI
- Covello: 24 个月验证期已过，离挣钱越来越远
- 缺乏终端付费意愿的需求是伪需求

罕有大的商业成功案例



历史重演：复刻 1999 年互联网泡沫逻辑——以叙事为手段，以泡沫为工具，转化为物理资产。前沿 AI 已从“商品”升格为“国家战略管控资源”。即便泡沫破灭，也会留下算力基础设施和人才。


数字世界光速迭代，企业落地是线性的。95% 的试点零 ROI 不是技术问题，是数字化基础、组织和商业节奏的问题。

【泡沫与商业】Stargate 投资链条：数据中心利用率是生死线，模型价格是关键

AI 输出不是复制存量内容，是实时计算：每一轮问答都消耗 GPU、HBM、电力，用量越大成本越高，广告收入覆盖不了算力成本

Oracle & OpenAI Stargate（星际之门）：1GW 数据中心怎么算账

- Oracle 负责投资建设、运营 4.5GW AI 数据中心
- OpenAI 向 Oracle 支付 4.5GW × 133 亿 ≈ 600 亿美元 / 年 刚性租金




超大科技公司把 AI 相关计算和网络设备折旧年限从 2-3 年拉长到 5-7 年，2026-2028 年合计少计折旧约 1760 亿美元

模型厂商：1GW 理论年收入 vs 2026 年盈亏（四家里只有 Anthropic 可能盈利）

模型厂商	旗舰模型	1GW 理论年收入	毛利	2026 年盈亏
OpenAI	GPT-5.6 Sol + Terra	255 亿美元	47%	亏损 90-110 亿美元
Anthropic	Opus 4.8 + Sonnet	234 亿美元	60%+	可能盈利
智谱 AI	GLM-5.2 + Flash	115 亿人民币	41%	亏损 40-52 亿
DeepSeek	V4-Pro + Flash	34 亿人民币	45%+	亏损 8-12 亿元

理论年收入的生死线 —— 利用率跌破 50% 或定价腰斩 → 单 GW 营收 < 180 亿

千亿级循环投资框架背后的逻辑 —— 梁文峰：投资算力大挣钱了




Source: Bloomberg

如果 OpenAI 增长不及预期，Oracle 的 600 亿刚性租金和债务就是第一个裂口


利用率是生死线：利用率跌破 50% 或定价腰斩，单 GW 营收就掉到 180 亿以内，整条链条的估值逻辑都会出问题——像房地产出现空置率一样。

【华为的机会】错过这波智能化浪潮的公司会落入平庸；时代在选择公司

全球市值前十（亿美元），2000—2026：每一波浪潮换一批赢家，2026 一整列都在浪尖上



华为营收（亿元），1992—2025：运营商和手机两大支柱见顶，下一条曲线是 计算 & AI



三个尺度对比

2GW

数据中心的建设成本 > 全球无线通信设备全部市场

40 倍

英伟达市值一度是 Intel 的 40 倍

爱立信 + 诺基亚 < 寒武纪

两家市值之和不如寒武纪一家

来源：原文图 12；市值（亿美元）与华为营收（亿元）为原图转录

Thank you.

任总："时代进步太快，时代在选择公司，我们没有办法躺平，我们要迎着时代的浪潮前进。"

华为要做的：不忘初心，放下傲慢，尊重产业发展规律。持续优化，不折腾，做最好的自己。

本胶片摘编自公众号「黄华书房」《再次遇到大时代》（2026-08-22）。文中判断与数字均为原作者观点与口径，图表按原文图重绘。

