

两个自研平台的建设总结：AI4News 与 AI 社区

一份汇报讲清两件事 —— 已经建成了什么，以及接下来怎么让它持续产生价值

19.9 万

行自研代码
两个平台合计，不含依赖与文档

151

张数据表
AI4News 79 + AI 社区 72

419

条路由 / 接口
AI4News 268 + AI 社区 151

843

个单元测试用例
AI4News 553 + AI 社区 290

476

次提交
两个平台均为单一作者

AI4News · 新闻情报与多模型工作台

把「新闻情报」和「多模型工作台」做进同一个平台：RSS 抓回来的文章逐篇打分、双语改写、聚成事件簇，再从新闻中心、个性化看板、定时邮件三个口子送出去；同一个问题可并排问最多 7 个模型，并自建 OpenAI 兼容网关供同事直接调用内网模型。

上线运行 · 301 天 · 372 次提交

AI 社区 · 知识沉淀与协作平台

六个板块：技能中心、知识库、讨论区、投票评选、极客视频、社区活动，共用一套账号、通知、评论与权限。目标是把个人的一次性产出，变成组织可复用、可检索、可被 AI 消费的资产。

上线运行 · 90 天 · 104 次提交

两个平台面向不同场景，但共用同一套内网模型与身份体系 —— AI4News 解决"信息进得来"，AI 社区解决"经验留得下"。

汇报目录：先看总体，再看各平台，最后看下一步

自顶向下四章，每章的核心结论列在下表

章节	内容	核心结论	页码
一	总体 规模与功能全景	两个平台合计 19.9 万行自研代码、151 张表、419 条路由、843 个用例，均由单一作者在内网环境从零搭建。AI4News 负责把外部信息处理成可用情报，AI 社区负责把内部经验沉淀为可复用资产，两者共用内网模型与实名身份体系。	3 — 5
二	AI4News 功能 · 工程 · 数据	三条产品线长在一个 Django 单体上：新闻情报中枢（采集→打分→双语改写→事件聚簇）、多模型工作台（7 模型并排 + 深度研究 + 舆论洞察 + 生图生视频）、平台底座（OpenAI 兼容网关 + 26 页运营后台）。	6 — 17
三	AI 社区 功能 · 工程	六大板块全部上线，账号、通知、评论、权限四套底座打通，新增板块无需重建。技术投入集中在并发一致性、权限单点收敛、内网条件下的能力自建、推理模型的工程容错四类问题上。	18 — 29
四	下一步 路径与投入	当前瓶颈不在功能供给而在参与转化。建议以「真人社区」为主线，专家专栏作栏目、AI 资源激励作放大器；第一批六项无外部依赖可立即启动，需决策的是额度授权、算力排期、运营配置与试点部门。	30 — 37


两个平台都已建成并稳定运行。本次汇报的重点是：把它们放在一起看清楚投入产出，并定下 AI 社区的下一步。

【总体】工程规模：19.9 万行自研代码，两个平台，一位作者

全部为内网环境下从零搭建，不含第三方依赖与文档；数据取自 git 统计与测试实测

AI4News2025-10-17 起 · 301 天 · 372 次提交	
自研代码	114,436 行（Python + JS/JSX + 模板）
数据表	79 张（含 3 张跨库只读表）
URL 路由	268 条（其中 API 类 67 条）
测试	553 个用例 / 45 个测试文件
节奏	116 个有提交的活跃日，月均约 37 次提交

AI 社区2026-05-22 起 · 90 天 · 104 次提交	
自研代码	85,190 行（TSX + TS + JS / CSS）
数据表	72 张（160 个索引与唯一约束）
服务接口	151 条（另有 72 个服务端渲染页面）
测试	290 个用例 / 26 个测试文件，1.17 秒跑完
节奏	28 个有提交的活跃日，月均约 35 次提交



- 共同的工程前提内网环境的三条硬约束
- 拿不到外网资源。依赖、字体、前端库全部本地化；AI4News 把 14 个前端运行时文件下到本地，AI 社区的命令行工具自带分发，均不依赖公共源。
 - 没有现成的中间件。对象存储、CDN、统一调度都不具备，因此媒体存储、任务调度、限流计量都要自建并留降级路径。
 - 模型分内外两路。外部模型统一走企业代理，内网模型直连，两套客户端策略完全不同——这条线同时贯穿两个平台。

两个平台合计约 20 万行自研代码、843 个自动化用例，全部在内网条件下从零建成，且均由单一作者持续维护。

【总体】功能全景：外部信息进得来，内部经验留得下

两个平台在同一条价值链的两端，共用内网模型与实名身份

AI4News · 让外部信息进得来	3 条产品线	AI 社区 · 让内部经验留得下	6 个板块
新闻情报中枢 订阅网站与关键词，抓回来的文章逐篇打分、中英双语改写、按事件聚簇。 89 条路由 · 35 张表	四个出口 新闻中心、个性化看板、定时邮件、详情页 AI 问答，同一份匹配结果四种消费方式。 13 个页面入口	技能中心 Skill 的发布、授权、免安装试用与一行命令安装；效果对比与 Remix。 从"各自留存"到"一次上传、多次安装"	知识库 六种来源入库，AI 逐章导读，问答带原文引用，共享标注。 从"各读一遍"到"一人读完、全员可问"
多模型工作台 一个问题并排问最多 7 个模型，答完自动出速览 / 融合 / 对比 / 追问四种汇总。 24 个模型注册项	长任务工具 深度研究、X 舆论洞察、生图生视频，各自后台线程运行，前端轮询状态。 最长可跑 15 分钟	讨论区 动态流与论坛话题并存，附件、反应、两级评论与主题归档。 从"群聊即焚"到"可检索、可沉淀"	投票评选 作品征集、审核、限票、匿名评选、明细导出的完整评选流程。 从"群里接龙"到"可审计的流程"
API 网关 改 base_url 即可用官方 SDK 调内网模型，带鉴权、限流与用量计量。 3 个兼容端点	运营后台 模型路由热改、用户与配额管理、抓取与投递监控。 26 个页面	极客视频 竖屏随刷短视频人人可发，自动中英双语字幕；长视频 AI 摘要与问答。 发布门槛降到一条手机视频	社区活动 全员可见日历，按浏览者时区显示，一键报名与开场前提醒。 从"一个邮件列表"到"全员可达"

两者的连接点：① 共用内网大模型 —— AI4News 的网关同时为社区的 AI 能力供能；② 共用实名身份与员工目录 —— 部门信息一处维护、两边生效；③ 信息链路互补 —— AI4News 把外部信息处理成可读情报，AI 社区把内部实践沉淀为可复用资产。

一句话概括两个平台的分工：AI4News 解决"看什么"，AI 社区解决"怎么做、跟谁学"。

【总览】一页看懂：三条产品线长在一个平台上

新闻情报中枢负责「把有用的信息找出来送到人手里」，多模型工作台负责「把大模型变成随手能用的工具」，平台底座让前两件事可管、可控、可计量。



新闻情报中枢

订阅任意网站或关键词，文章抓回来后逐篇打分、双语改写、按事件聚簇，再从新闻中心、个性化看板、定时邮件三个口子送出去。

- 订阅** 网站链接 / 关键词 / 关注同事，解析不出 RSS 自动兜底
- 加工** 相关性打分 → 中英双语改写 → 向量去重与事件聚簇
- 出口** 新闻中心 · 个性化看板 · 定时邮件 · 详情页 AI 问答

89 条路由 · 35 张表 · 13 个页面入口



多模型工作台

同一个问题并排问最多 7 个模型，答完自动出速览、融合、对比三份汇总；深度研究、X 舆论洞察、图片与视频生成共用一个工作区。

- 对话** 7 路并排流式 + 速览 / 融合 / 对比 / 追问四种汇总
- 研究** 深度研究报告 · X 平台舆论洞察 · 可复用提示词技能库
- 生成** Sora 视频 · Imagen 与 gpt-image 生图 · 文档转图附件

14 个可选模型 · 50 条路由 · 19 张表



网关与运营底座

自建 OpenAI 兼容网关，同事拿一个 Key 就能调内网 vLLM；限流、配额、逐次计量、异常告警和 26 个后台页面把整个平台管起来。

- 网关** 鉴权 · 限流 · 日配额 · 模型路由热改 · 五维 token 计量
- 后台** 用户与权限 · 内容 · 用量明细 · 告警 · 员工名册
- 监控** vLLM 实时负载、四组延迟直方图、4 类异常自动检测

五维 token 计量 · 69 条后台路由

规模：2025-10-17 起 301 天、372 次提交，一个人写出 114,436 行自研代码 —— 8 个 Django 应用、79 张表、268 条路由、553 个单元测试用例、41 个第三方依赖。

三条线不是三个项目：它们共用一套用户、一套模型注册表、一套用量账本，所以加一个模型、改一条权限，三处同时生效。

【总览】系统分层：一个 Django 单体，五层各管一段

示意图。模型层的分叉是这套架构最关键的一条线 —— 外部模型统一走企业代理，内网模型直连，两套 HTTP 客户端策略完全不同。



一个设计决定贯穿全图：所有模型的 id、端点、密钥、走不走代理都收在 `ai4news/model_registry.py` 一个文件里。加一个内网模型只改这一处，前端下拉、后端 client、代理策略三处自动跟上；内部服务调模型还会回环走自家网关，顺带吃到限流、配额和计量。

单体不等于耦合 —— 边界划在服务层，四个应用各自独立，共享的只有身份、模型注册表和用量账本这三样。

【新闻智能】主链路：抓回来 → 打分 → 双语改写 → 聚成事件簇

六个环节全自动，每 30 分钟推一轮；RSS.app 的 webhook 还有一条实时旁路，来了新文章直接开线程处理，不排队。



关键参数与背后的取舍			全部回代码核实
环节	关键参数	为什么这么定	
调度	Beat 每 30 分钟一轮；每个用户再按自己的评估间隔节流（默认 20 分钟，下限 5 分钟）	抓取和评分分在不同队列，互不阻塞；打开看板会顺手投递一次匹配，但有双重节流，刷新页面打不爆队列	
评分缓存	<code>prompt_signature</code> = sha256(prompt + 阈值 + 分类 + 关键词)	用户改一个字，签名就变，历史文章自动重新进候选队列 —— 不需要手工触发全量重算	
去重	余弦 ≥ 0.92 判为重复；判重的文章也写一行分数为 0 的记录	这行记录带着当前签名，下一轮候选查询直接把它排除，重复文章不会被反复捞回来重算	
聚类	48 小时窗口、余弦 ≥ 0.82 （用户可调），按分数降序贪心归簇	因为按分数降序，簇代表天然就是簇内最高分那篇；看板和邮件都只发代表，同一事件不会刷屏	
容错	评分失败、落库失败、翻译失败、聚类失败各自隔离	一条脏数据只跳过它自己，不影响这个用户这一轮的其余文章；有专门的回归测试覆盖	

去重和聚类共用同一份向量缓存，聚类那一步不再调模型 —— 存的是归一化向量，点积就是余弦。

【新闻智能】同一份匹配结果，四个口子送到人手里

底下都是 UserNewsMatch 这一张表，上面按「逛 / 查 / 收 / 订」四种使用习惯做了四套界面。

新闻中心 Hub

- Forbes 式首页：滚动热门标题条 + 三栏全屏 + 自动轮播卡片行
- 一次查询取 24 小时内 120 条，在内存里切成头条 3 / 热门 6 / 突发 5 / 滚动 12 四段，跨板块不重复
- 突发的判定是 12 小时内且评分 ≥ 0.85
- 两级分类导航，子分类没配来源就继承父级
- AI 简报每 6 小时一版，3 条要点
- 卡片点开是共享弹窗：收藏、复制链接、复制分享文案、下载分享图、关注来源用户
- 分类落地页带二级子分类横条，滚到底自动加载下一页 12 条

个性化看板

- 三栏可拖拽：筛选 / 列表 / AI 对话
- 全文检索走 PostgreSQL 原生索引，标题 A 权重、摘要 B 权重，命中不足自动降级
- 可按来源、关键词、作者、我的分类、日期、关注的同事六个维度筛
- 只显示簇代表，相似的收在「+N 相似」里
- 右侧 AI 对话可带最多 5 篇文章当上下文
- 排序可选时间或分数，每页 20 / 50 / 100 条
- 打开页面时若距上次匹配超过间隔，自动补投一次匹配任务，带双重节流

邮件摘要

- 取数三段式：本人匹配 $\rightarrow$ 关注同事的匹配 $\rightarrow$ 订阅源内最新兜底，兜底严格限定在自己人的源里
- 三重去重：ID、归一化 URL、标题字符集相似度 ≥ 0.45
- 日 / 周 / 月 / 单次四种频率，下次发送时间在用户时区里算
- 月历视图 + 编排面板 + 发送历史快照
- 可自定义主题、Logo、三个主题色，条数 1—200、时间窗 1—720 小时
- 两档权限：有完整权限才能发给收件人列表，其余降级为只发给自己
- 支持跳过下一次、用冻结快照发送，单次计划发完自动停用

订阅与反馈

- 粘任意网站链接就能订：解析不出 RSS 就自动调 RSS.app 生成一个
- 也能按关键词订，或者直接关注同事的新闻流
- 最后一个订阅者退订时，本地和远端的 feed 一起删，省外部服务配额
- 订阅中心按管理员编排的分类批量点选
- 批量导入一次收网站链接、RSS 地址、关键词三类输入，带进度回显
- 关键词包和提示词模板可一键整包套用
- 建议板是看板形态：四列拖拽、楼中楼评论加点赞、进度条、管理员回复

另外三处：新闻详情页做了双语逐段对照 + 嵌套评论 + 全站向量相似的相关新闻 + AI 问答；用户公开主页带关注按钮和热门 / 最新两个 tab；收藏、浏览历史（保留最近 100 条）和工作台构成个人沉淀区。

四套界面共用一张匹配表，所以调一次个性化参数，新闻中心、看板和明早的邮件同时跟着变。

【多模型】一个问题问 7 个模型，答完自己出汇总

这是站点首页。前端对每个选中模型各开一条 SSE 流并排渲染，谁先答完谁先显示，不用等最慢的那个。

做了什么

■ 并排流式作答。最多同时选 7 个模型，各走各的连接互不阻塞；栅格列数按选中数自动变。

■ AI 汇总四种模式。速览、融合、对比、追问。速览是增量的：每有一个模型答完就用现有答案重跑一遍，不等最慢的；全部答完再并行发融合和对比。

■ 汇总有硬约束。融合禁止按模型分块罗列、必须标来源；对比固定「综合答案 / 共识 / 分歧 / 独特洞察 / 数据对照表」五段。

■ 多模态附件双通道。视觉模型走「文档栅格化成图」，纯文本模型走「抽正文塞进 system 消息」，同一个上传按钮自动分流。

■ 用户可自带 Key。用站点 Key 的走每日 token 配额，自带 Key 的不计配额、单独记账。

■ 汇总结果也落库。用三个保留标识单独存，切回旧会话时速览、融合、对比都还在；中途出错的半截结果不落库。

■ 错误隔离到单个模型。某一路流挂了只写坏它自己那一栏，其余模型照常输出，页面不会整块白掉。

企业代理的 1MB 上传限制：大文件按 900KB 分片上传，分片落盘而不是留在内存，这样多个 gunicorn 进程谁收到都能续上，最后一片到齐才拼接。

接入的模型			24 个注册项 · 14 个可在对话里选
位置	模型	用途	
外部 · 走代理	ChatGPT · Gemini · Grok · Qwen	4 家、14 个可选模型 id	
内网 · 直连	GPT-OSS-120B · GLM-4.6V · Gemma-4 · MiniMax-M2.7 · GLM-5.2 · DeepSeek-V4	6 个本地对话模型，其中两个多模态	
汇总与摘要	GLM-5.2 · MiniMax-M2.7	AI 汇总四模式 / 多源摘要合并	
新闻加工	DeepSeek-V4-Flash	逐篇打分 + 中英双语改写	
向量	Qwen3-Embedding-8B	去重、事件聚类、相关新闻	
重活工具	o3-deep-research · Gemini Deep Research · Grok x_search · Sora-2 · Imagen · gpt-image-1	深度研究 / 舆论洞察 / 生图生视频	

新增一个内网模型只需要在注册表里加一条，前端下拉自动出现 —— 不改前端、不改 provider 代码。

并行问模型最怕被最慢的一个拖住，所以汇总做成增量的：先出一版速览，谁答完就补一版。

【多模型】三个跑得久的工具：深度研究、X 舆论洞察、生图生视频

这三样都不走 Celery，各自起后台线程跑、前端轮询状态 —— 不占队列，worker 重启也不影响正在跑的任务。

深度研究

- 一次可以同时勾 OpenAI 和 Gemini 两家，各起一条线程；每 10 秒轮询一次，最长跑 15 分钟
- 报告出来后自动生成 3—5 句摘要插到最前，再把 markdown 里的链接抽成引文表
- 提示词技能库可复用：系统技能 + 私有技能，8 个分类，带收藏和使用次数排行
- 报告页有引文悬浮预览、批注、讨论串和针对本报告的 AI 追问（历史存服务端）
- 可导 PDF / Word / 邮件，也可公开到报告广场
- 自动触发的通路完整保留但全局关闭；真跑起来时三层去重：同用户同文章、同事件簇、向量相似
- 技能优先级：请求指定 > 用户默认 > 磁盘上的技能文件 > 硬编码兜底

X 舆论洞察

- 用 Grok 的 x_search 抓 X 平台实时讨论，产出一个仪表盘而不是一篇报告
- 模型被要求按命名 JSON 块返回 7 个模块：总览、热帖、观点分立场、关键账号、热门标签、高赞评论、时间线
- 解析失败会先清一遍尾逗号重试，再不行就把原始文本存下来，不丢数据
- 可挂 influencer 名单做定向分析，名单里的 handle 自动合并进搜索白名单
- 同样支持公开分享和 PDF / Word / 邮件导出
- 热帖最多 30 条，按浏览量、点赞、转发、账号影响力排序；高赞评论最多 10 条
- 前端用引用保存当前报告，避免定时器闭包过期导致跑完自动跳错页

图片与视频生成

- 聊天里直接说「画一张...」，模型自己调生图工具，出图后按 markdown 语法拼进回答正文
- 也有独立入口：Imagen 三个模型五种比例，gpt-image-1 三种尺寸四档质量
- OpenAI 不返图片成本，所以从 PNG 头解出真实尺寸，再查 3x3 的价目表自己算，存进库里
- Sora-2 视频：两个模型、4/8/12 秒、两种 720p，每 4 秒轮询一次进度
- 成品不直连外部，走后端代流下载，按内容类型决定文件名
- 生成的图片直接以 base64 存库，一行 1—2MB，同时记下估算成本
- 参数不在白名单一律回落默认值，不把非法参数透传给上游

AI 洞察中心

- 第六个 Django 应用，挂在 /ai-hub/，1,057 行、15 条路由、3 个模板
- 结构和新闻中心对称但独立存储：自己的来源配置、突发阈值、滚动条数
- 每日精选视频一天一条，视频文件 / 外链 / 嵌入代码三选一按优先级回退
- GitHub 趋势榜带缓存表，不用每次现抓
- 自带一套管理界面，和主后台同一把权限锁
- 三个模板共 750 行，独立于新闻中心的前端代码
- 和新闻中心共用同一份用户匹配数据，不重复抓取

共同的工程模式：后台线程首尾各做一次数据库连接回收，中间每一步单独 try/except —— 摘要生成挂了、引文抽取挂了、用量记账挂了，都不影响报告本体存下来。

跑十几分钟的活儿放进 Celery 会挤占队列，也扛不住 worker 重启，所以这三样都用后台线程加前端轮询。

【网关与运营】自建 OpenAI 兼容网关 + 26 个页面的运营后台

同事把 base_url 改成 /model/v1/、拿一个 ak- 开头的 Key，就能用官方 SDK 调内网 vLLM，代码一行不用改。

API 网关

3 个 OpenAI 兼容端点

鉴权。

Key 明文不入库，只存 SHA-256 哈希；校验走 60 秒缓存，无效 Key 也缓存，防止猜 Key 每次都打数据库。

限流与配额。

默认每分钟 60 次、每天 100 万 token，超了返回 429 带 Retry-After；配额用增量缓存累加，不是每次都做聚合查询。

模型路由由后台热改。

「用户看到的名字」到「上游 vLLM 地址 + 真实模型名」的映射存在表里，管理员改完 30 秒缓存主动失效，不重启生效。

多维计量。

每次调用记一行：输入 / 输出 / 命中缓存 / 写缓存 / 合计五种 token 分开记，上游挂了也照样记一行。

异常检测。

4 类异常每 15 分钟扫一遍；自动封禁要同时过三道闸，专门防新 Key 基数小导致的误伤。

白名单按 Key 粒度。

每把 Key 能调哪些模型单独配，模型列表接口也按同一份白名单过滤，用户只看得到自己能用的。

类型隔离。

对话模型和向量模型分开登记，对话端点不可能被路由到向量模型上，报错时还会列出可用清单。

60/分

默认限流

100万/天

默认 token 配额

18

采集的 vLLM 指标

3级

用量聚合：请求 / 日 / 时

运营后台		19 条一级导航 · 69 条路由
页面	管什么	
数据概览	一次 GET 算完用户 / 新闻 / 浏览 / 订阅 / 邮件 / 报告 / 对话七组指标，外加 30 天日序列和 12 周周序列	
用户与权限	五字段搜索 + 部门筛选；10 个权限开关可单改，也可用全局策略一次刷全员，新用户自动继承	
订阅源 / 新闻	源和文章的增删改查，支持手工入库一条新闻（抓正文 + 双语翻译 + 给全员建匹配）	
员工名册	粘贴 / CSV / XLSX 三路批量导入，按工号把部门和研究所同步到用户	
API 用量	四个时间窗 × 五种 token；使用明细支持用户 / 模型双维度、任意日期区间、Excel 导出和命名预设	
负载监控	直接抓每台 vLLM 的 /metrics：运行数、排队数、KV cache 占用、吞吐、四组延迟直方图	
告警与审计	异常告警处理 + 每个写操作都留一条带前后差异的审计日志 + 页面访问追踪	

用量这件事只认一张原始日志表，日表和小时表都是从它算出来的，所以后台哪个页面看到的数字都对得上。

【工程亮点】六个踩过坑才定下来的做法

都是线上出过问题、改完有明确收益的地方，不是设计文档里的理想方案。

① 抓取热路径零数据库写

- 老实现是抓一篇写一篇，一条数据库连接被几十篇文章的慢网络占住
- 改成解析、抓正文、内存加工三段全程不碰库，最后 50 条一个事务落库
- 事务窗口从「整个源的抓取时长」压缩到「一次批写」；整批失败自动降级逐条
- 已经有正文的文章直接跳过抓取；源自报的构建时间没变就一个字节都不写

② 长连接的连接与心跳

- 流式响应返回前先把数据库连接还回池子 —— 一条连接被十几分钟的 SSE 占住，池子扛不住
- 生产者线程 + 队列，10 秒拿不到事件就补一个心跳，防代理和 nginx 掐断
- 响应头关掉 nginx 缓冲，前端配两次自动重连
- 评分线程进出各做一次连接回收 —— LLM 调用是分钟级的，不主动关会把池子吃穿

③ gevent + psychogreen

- gunicorn 用 gevent，每进程 200 个协程扛 LLM 转发这种长 IO
- 但 psychopg2 默认是阻塞的，一条数据库查询就能把整个进程的协程池卡死
- 在 post_fork 钩子里打补丁，把等待交回调度器 —— 不打这个补丁等于白用协程
- 超时设到 1800 秒，因为深度研究那条流本来就要跑十几分钟

④ 后台慢查询重写

- 订阅源列表原来每行挂两个 COUNT 子查询打在巨大的新闻表上，一页 60 行
- 改成两条 GROUP BY 一次算完 + 10 分钟缓存
- 新闻列表原来一条查询里两个 COUNT(DISTINCT)，PostgreSQL 要建笛卡尔积临时表，直接把磁盘写满；改成两个独立子查询避开 join

⑤ 模型注册表单点收口

- 24 个模型注册项的 id、端点、密钥、走不走代理集中在一个文件
- 前端配置由它自动生成，加一个本地模型只改这一处
- 外部模型走代理、120 秒超时；内网模型直连、读超时不设上限 —— 两套客户端策略由注册项自动决定
- 内网客户端显式不读环境变量，免得被全局代理设置劫持

⑥ 先预检再动线上进程

- 热重载脚本五个阶段：wsgi 导不进来、有未应用的迁移、JSX 比构建产物新，任一不过就直接退出，老进程原封不动继续服务
- 重载信号必须打给主进程，打错目标只会杀掉一个 worker
- Celery 重载完睡 5 秒再数一次进程，少了就报错而不是假装成功
- 全量重启时静态收集失败即中止，不带着半套静态资源起服务

这六条的共同点：先让系统在出错时不塌，再谈快 —— 单篇失败只跳过单篇，整批失败降级逐条，预检不过就不动线上。

【工程规模】11.4 万行自研代码，301 天，372 次提交

2025-10-17 第一次提交，2026-08-14 最近一次，其间 116 个有提交的活跃日，单一作者。

114,436 自研代码行数 (Python + JS/JSX + 模板)	79 数据表 (含 3 张跨库只读表)	268 URL 路由 (其中 API 类 67 条)	553 单元测试用例 (45 个测试文件)	372 次提交 / 301 天 (月均约 37 次)
---	---	--	---	--

各应用后端代码行数		不含数据库迁移
news		21,139
multillm		14,172
api_gateway		6,765
admin_panel		4,327
core		2,625
ai4news		1,536
ai_hub		1,057
MCP server		607
前端自研文件 top 5 (共 34,100 行 / 31 个文件)		
app_view.jsx		5,886
personalization		5,712
dashboard.js		2,790
news_hub.js		1,771
i18n.is		1,486

代码构成	
后端 Python	52,228 行 / 161 个文件
数据库迁移	7,192 行 / 114 个文件
前端 JS + JSX	34,100 行 / 31 个文件
Django 模板	20,916 行 / 64 个文件
测试代码	9,312 行，占业务 Python 约 18%
第三方依赖	41 个
最大单文件	news/views.py 4,930 行 app_view.jsx 5,886 行

测试是 553 个用例、9,312 行，全部不连数据库不连网络，所以在开发机上秒级就能跑完一轮回归。

【工程规模】 前端不依赖外网， 部署一条命令

内网环境的两个硬约束：外网 CDN 拿不到，浏览器不能现场编译。前端工程链就是围着这两条搭的。

前端工程

■ **JSX 预编译**。esbuild 6 个入口编译成 dist 产物随仓库走，浏览器不再跑 Babel；不做打包，因为各文件本身自包含，模板改动不用动构建。

■ **零 CDN**。React、marked、DOMPurify、KaTeX、Chart.js、Cropper、Tailwind 运行时和 Inter 字体共 14 个文件全下到本地，内网断外网照常打开。

■ **三语**。1,269 条文案配齐中 / 英 / 法，共 3,807 条译文；用 data-i18n 属性驱动，切换时派事件让 React 组件重渲染。

■ **可视化**。9 个页面用 Chart.js 画看板，全部带缩放插件；分享图是前端手写 Canvas 排版，先离屏测量换行再按算出的尺寸绘制。

■ **静态资源版本号**从构建清单的修改时间派生，保证所有进程给出同一个 URL，浏览器缓存才生效。

■ **组件复用**。AI 对话 widget 一份代码同时服务新闻详情页和深度报告页，两边只换取数回调。

■ **混合渲染**。9 个页面用 React，其余是原生 JS 加属性绑定，没有全站统一框架的包袱。

■ **只有一个手写 CSS 文件**（邮件编排页 344 行），其余页面全部走 Tailwind 运行时。

部署形态

单机 · 一条命令起停

组件	配置
Web	gunicorn 5 进程 × gevent 200 协程；超时 1800 秒（给长流式留的）；每 1000 个请求回收一次进程
后台任务	5 个队列 / 4 组 worker / 12 个子进程 + beat；8 条定时任务，最密的每 5 分钟一次
数据库	PostgreSQL；连接池每进程常驻 10 + 溢出 15，600 秒回收，取连接前先探活
缓存	DatabaseCache，同时兼任分布式任务锁和后台列表页的计数缓存
日志	9 路按功能分流（错误 / 新闻 / 多模型 / 深度研究 / 洞察 / 网关 / 鉴权 / 任务），各 20MB × 5 备份
运维脚本	restart.sh 全量重启（88 行）· reload.sh 五阶段热重载（225 行，先预检）· envcheck.py 环境自检 · recover.sh 一键恢复
配置	所有环境变量收在一个入口文件，生产改配置 = 改一个文件、提交、拉取、重启

可选组件全部优雅降级：少了哪个第三方库就把它从已安装应用里摘掉、只打一条警告，不会让整站 URL 配置崩掉返回 500。

【数据结构】79 张表按七个业务域组织

整张 schema 围着 News 这一张内容主表展开，往上叠订阅与个性化、多模型与研究、网关计量三层。

业务域	表数	代表表	说明
内容	5	News · RssFeeds · RssItems · Webhook 配置与投递	文章主表把原文、双语四份文本、关键词命中和向量放在同一行，加一个布尔位标记「已评分且已翻译」
用户与订阅	14	User · SsoProfile · EmployeeDirectory · 订阅源关系 · 关注同事 · 分类 · 关键词包	个性化 prompt、相关性阈值、聚类阈值、每日 token 配额全长在 User 上，共 33 个自定义字段
匹配与行为	7	UserNewsMatch · 匹配分类 · 浏览 · 收藏 · 历史 · 评论	UserNewsMatch 是行数最大的表（用户 × 文章量级），既是打分缓存也承载事件聚簇的三个字段
新闻中心与邮件	10	Hub 配置 · Hub 分类树 · 卡位 · AI 简报 · 收件人 / 草稿 / 计划 / 投递日志	编排数据和投递审计分开存；投递日志记下发过哪些文章 ID，用来防重复推送
多模型与研究	19	会话与消息 · 深度报告及 5 张附属表 · X 洞察 · 生成图片 · 模型活配置与用量	报告、洞察都带公开分享位；模型的真相源在代码注册表，数据库这几张只做运行时覆盖
网关计量	10	APIKey · 用量日志 / 日表 / 小时表 · vLLM 指标及降采样 · 模型路由 · 异常	逐请求日志是唯一真相源，日表和小时表都从它算出来；五种 token 在三张表里字段名完全一致
运营与其它	14	审计日志 · 页面访问 · 更新公告 · 建议板三表 · AI 洞察中心四表 · 微信跨库三表	其中 3 张是只读映射到第二个数据库的表，Django 不管理它们的结构，靠路由分流

索引与半结构化字段：61 个显式复合索引 · 23 个单列索引 · 20 组唯一约束 + 5 个唯一约束对象 + 1 个检查约束（数据库层禁止自己关注自己）· 38 个 JSONField · 15 个数组字段 · 6 条手写 PostgreSQL 索引（2 个全文检索 + 2 个模糊匹配 + 2 个 B-tree）。

表多不等于乱：七个域各有自己的入口表，跨域引用只走 User 和 News 这两张，别的地方不互相穿。

【数据结构】六个撑住整个系统的设计决定

这几处定错了，后面每一层都要绕着走 —— 所以单独拿出来讲。

对象	关键设计	为什么这么做
News · 主键	不是自增也不是 UUID，是 <code>sha256(源ID:条目ID)</code> 取前 68 位	确定性主键，同一篇文章重复抓多少次都是同一行 —— webhook 重投、定时轮询和手工入库三条路天然幂等
News · 一行装四份文本	原标题 / 英文 / 中文，正文和摘要各一套，再加向量、关键词命中和一个「已加工」布尔位	下游看板、邮件、相关新闻都只认这个布尔位，避免把只抓回来还没翻译的半成品发出去
UserNewsMatch · 签名	存一个 <code>prompt_signature</code> ：prompt、阈值、分类、关键词拼起来的哈希	用户改配置签名就变，候选查询把旧签名的记录排除掉，历史文章自动重新排队 —— 不需要另写一套失效逻辑
User · 三合一	身份、个性化参数、配额长在同一张表，33 个自定义字段	代价是保存时带副作用（改个性化参数会重置评估状态），所以员工名册同步刻意绕开保存方法，直接批量更新两列
用量 · 三级聚合	逐请求日志 → 按天汇总 → 按小时汇总；五种 token 三张表字段名一致	原始表不删，聚合表只是加速；口径统一到一处，后台任何页面的数字都能对上，也方便按官方计费口径拆开看成本
检索 · 不外挂引擎	News 上手写 2 个全文检索索引 + 2 个模糊匹配索引，标题 A 权重、摘要 B 权重	省掉一个搜索引擎组件；中文用兼容配置，命中不足时代码自动降级到普通包含匹配，不会搜不出东西

0.92

向量去重阈值

0.82

事件聚类阈值（可按用户调）

0.60

默认相关性阈值

48小时

聚类时间窗

5维

token 计量口径

这六条里有四条都是同一个思路：把「什么时候该重算」编进数据本身，而不是另写一套缓存失效逻辑。

【能力现状】平台全景：六大板块 + 四套共享底座

下列能力均已在内网上线运行，不含规划项

技能中心 含合集包

Skill 的上传、评分、版本与订阅；公开 / 受限 / 私有三档可见性与逐人审批；命令行一行安装；免安装试用；带与不带 Skill 的问题实测对比；Remix 二次创作并保留署名。

从"各自留存"到"一次上传、多次安装"

知识库

网页链接与 PDF / EPUB / PPT / Word 入库；AI 逐章导读；问答附带原文引用并可跳转；划线批注与共享笔记；选中即译；阅读进度跨设备保持。

从"各读一遍"到"一人读完、全员可问"

讨论区

动态流与论坛话题两种形态；图片 / 视频 / 文档附件；六种表情反应；两级评论与通知深链定位；多主题归档与浏览量按人按天去重。

从"群聊即焚"到"可检索、可沉淀"

投票评选 最新上线

作品征集与审核；每人限票、按天配额、撤票改投；匿名评选与随机排序；实名一人一票；实时榜单、投票明细导出存档。

从"群里接龙"到"可审计的评选流程"

极客视频 含随刷短视频

竖屏随刷短视频，成员均可发布；发布后自动生成中英双语字幕；长视频 AI 看点摘要与就视频问答；点赞、收藏、评论与全站互通。

从"看完即沉"到"可检索的技术影像资产"

社区活动

全员可见的活动日历；按类型 / 主题 / 城市 / 形式筛选；按浏览者所在时区自动换算；一键报名与开场前自动提醒；导出至 Google / Outlook 日历。

从"一个邮件列表"到"全员可达"

四套共享底座（第 12—13 页展开）：① **统一账号** —— W3 单点登录与邮箱密码双通道，部门信息按工号自动同步；② **统一通知** —— 全站消息汇入一个入口，按类型分渠道可控；③ **统一互动** —— 评论、反应、深链定位一套实现；④ **统一权限** —— 三档可见性 + 服务端裁剪，网页与命令行同一判定。

工程含义：新增第七个板块时，账号、通知、评论、权限四项不需要重建，只需接入。这是平台化与"多个小站拼装"的本质区别。

启示：功能建设阶段已经收敛，后续投入应从"扩展板块"转向"提升参与"。

【能力现状】系统架构：四层结构，一套代码两种部署

公网根路径与内网 /ai-community 子路径共用同一份工程，无分支维护



三项关键工程决策：① 出网按目标主机分流，而非全局开关 —— 内网地址直连、公网地址走代理。若采用单一开关，必然出现"启用代理则 W3 登录不可用、关闭代理则知识库无法抓取"的两难。② 鉴权由应用承担、字节由 nginx 承担 —— 视频数据不经过应用进程，避免并发拖拽进度条时单线程被占满。③ 配置分级失败 —— 安全类配置校验不通过即终止启动，非关键参数回落默认值。

可自查：管理后台内置网络出口、邮件、模型连通性三项诊断，直接输出真实错误码与实际路由选择，不以"网络异常"笼统提示。
可回归：26 个测试文件、290 条用例，全量执行不足 1 秒且不依赖数据库。

启示：内网环境不具备对象存储、CDN 与公网直连，能力必须自建且每一项都要有降级路径 —— 这是本系统全部架构取舍的共同前提。

【能力现状】技能中心：Skill 的发布、试用、安装与更新

一个 Skill 从上传到进入他人项目，全流程无需线下沟通



详情页的八个标签页		装之前就能判断值不值得装
概览	用途、适用场景、作者、安装量、评分、可见性	
说明文档	作者撰写的完整 Readme	
文件浏览	安装前逐个文件查看内容 —— 装进项目前先看清楚里面是什么	
版本历史	历次更新说明，可安装指定版本	
评价	用过的人的评分与评论	
组合推荐	大家通常还会同时安装哪些 Skill	
效果对比	同一任务、同一模型跑两遍（带与不带该 Skill），并列展示真实输出与差异分析	
在线试用	不安装即可与"已加载该 Skill 的模型"对话；切走页面不中断生成	

命令行

内网无 npm 源，工具自带分发

skills install <名称> 装到当前项目

skills install a b c 一次装多个

skills install pack:<合集> 整套装齐

skills list / update / upgrade / search

默认装进当前项目并记录版本与来源；加 -g 装到全局。更新失败自动回滚。

此处放：Skill 详情页截图

建议截「效果对比」或「在线试用」标签页

在编辑器中点「进入编辑」后 Ctrl+V 粘贴

此外：Remix 二次创作（改后发布为自己的，保留来源署名）· 合集包按场景整套安装 · 订阅更新提示 · 按分类 / 评分 / 来源筛选排序。网页与命令行共用同一套访问判定，不会出现"网页拦住、命令行没拦住"的情况。

启示：Skill 是社区中唯一直接进入他人生产流程的资产，因此"装之前能看清、装之后能更新、撤权后即断更"三件事必须齐备。

【能力现状】知识库：一人读完，全员可问

六种来源入库、AI 逐章导读、带引用问答、共享标注，构成一套完整的团队阅读流程

① 入库

贴网页链接，或上传 PDF / EPUB / PPT / Word / HTML；自动提取正文、封面、作者与阅读时长，重复提交自动识别。

② AI 通读

生成整体导读与逐章摘要，中英双语；结果全站共享，第二位读者无需重复调用模型。

③ 阅读与标注

四色划线、写批注、选中即译；支持连续滚动与分章两种模式，字号行距可调。

④ 提问与讨论

就本文提问，答案附可跳转引用；文档下可评论、可评分、可加入书架。

阅读与标注

把个人阅读变成团队资产


- **共享标注**：开启“公开我的笔记”后，同事读同一篇时能在原文位置**看到你的划线**，并可针对某一条划线开讨论——相当于在文档上做异步共读。
- **个人笔记面板**：本篇的全部划线与批注集中查看、可跳回原文位置。
- **选中即译**：读英文论文时选中一段就地给出中文，反之亦然，不必把内网内容贴到外部工具。
- **阅读进度**：记录读到第几章、百分之多少，换台机器继续读；可加入书架。
- **PDF 双视图**：原版按原貌阅读，精读视图支持划线、批注与 AI 引用跳转。

提问与协作

- **带出处的问答**：每句结论后跟一个可点角标，点击跳回原文并高亮，可当场核实 AI 是否如实转述。
- **整体导读结构化**：概述、内容脉络、核心要点、值得追问的问题四段，30 秒判断这篇值不值得精读。
- **文档评论与评分**：读后感与推荐度沉淀在文档下方，供后来者参考。
- **相似文档推荐**：读完一篇给出相关的其他文档。
- **可见性三档**：公开、受限（可申请）、私有；按类型与主题分类筛选。

此处放：阅读器截图

建议截「划线 + 共享标注」
或「提问后引用跳回原文」的画面



知识库列表（演示数据）

AI 给出的引用与用户手工划线落在同一套文本坐标上，因此二者可以互相跳转——这是“答案能当场核实”的前提，也是本模块与普通文档库的根本区别。

启示：知识库的价值不在存了多少文档，而在同一份材料只被深读一次，其余人以问答方式复用。

【能力现状】讨论区：随手发的动态与要沉淀的话题

同一入口两种形态，共用附件、评论、通知与检索能力

动态流


轻量 · 随手记录

- 一条动态可带 9 张图 + 1 个视频 + 4 个文档：视频卡内直接播放并可拖进度；PPT / Word 点击下载且保留中文原文件名。
- 六种表情反应（赞 / 精彩 / 支持 / 喜爱 / 有启发 / 有趣），悬停展开选择，点击数字可查看谁点了哪一种。
- 两级评论：回复的回复仍归在同一楼，不无限缩进；他人回复你时，通知点击直达该条并自动展开所在楼层。
- 可插入投票与表情包，管理员可置顶。

论坛话题

沉淀 · 可检索

- 一个话题最多挂 3 个主题（模型与算法 / Agent 与工具 / Skill 开发 / 前沿研究 / 技术交流 / 问答求助 / 经验分享 / 成果展示），在每个主题下都能被找到。
- 左侧主题导航显示各主题的话题数量，一键分流。
- 列表可见"谁在聊、多少人看过"：最近参与者头像、回复数、浏览量（**按人按天去重**，同一人反复刷新只算一次）。
- 支持顶帖；管理员可置顶、加锁；话题可带附件。
- 半年后仍可通过全站检索找回。



讨论区界面 —— 顶部为「动态 / 讨论帖」两个标签，右栏常驻热门讨论（演示数据）。

此处放：论坛话题详情截图

建议截带主题标签、参与者头像与两级回复的画面

单视频 1 GB、单文档 100 MB，每人每日 5 GB 上传额度；匿名访客可看正文与图片，视频与文档需登录。删除带回复的评论时保留楼层结构，计数不会因并发操作而错乱。

启示：轻量与沉淀分流之后，群聊里"刷过即失"的内容第一次有了可检索的落点。

【能力现状 · 最新上线】投票评选：从作品征集到结果公示

组织者不需要再用群接龙与表格统计，全流程在平台内完成并留痕



组织者

建活动与管过程

- **两种作品来源**：批量上传（**按文件名规则自动解析作品名 / 作者 / 工号**，人工改过的条目不被覆盖）；或开放成员自主投稿。
- **投稿表单可定制**：作品名、作者、工号、作品描述之外，可自定义字段；可写投稿须知、限制单人投稿数与文件大小；驳回时填写理由（仅投稿者可见）。
- **规则可配**：每人票数、按总量或按天发放、单件作品投票上限、是否允许撤票改投、截止时间、结果公开时点。
- **过程可管**：滚动公告条随时改、封面自定义、作品可临时下架（票数保留）、可提前结束。
- **数据看板**：实时排名、参与人数、每件作品的去重投票人数与投票人名单，一键导出 CSV 存档。

参与者

看作品与投票

- **作品墙 + 大图灯箱**：点开看大图或播放视频，右侧是作品详情（描述、表单信息）与评论区。
- **匿名评选**：投票期只显示编号不显示作者，结束后公示 —— 评的是作品本身。
- **顺序对每个人都不同**（随机但对同一人稳定），避免排在前面的天然占便宜。
- **按编号搜索**，方便"投 42 号"这类口口相传的场景。
- **票数余额实时可见**，支持改投与撤票；倒计时提示剩余时间。
- **未开始 / 已结束状态清晰**，结束后仍可浏览作品与结果。

此处放：投票活动页截图

建议截作品墙（含倒计时、我的剩余票数），或大图灯箱 + 右侧作品详情与评论区

结果为什么可信：票数不做累加，每次投票都从选票明细重新统计，改票、撤票、并发投票都不会对不上；内网部署下投票**强制要求 W3 实名身份**，邮箱注册的账号不予放行，一人一件作品一天仅一条记录。

启示：该模块的通用性高于单次活动 —— **作品征集、限票、匿名评选、明细导出可直接支撑各部门的评优与征集**，无需二次开发。

【能力现状】统一编辑器：写字的地方都具备同一套能力

19 处输入框、36 个展示页面共用一套编辑与渲染，新增板块自动继承

19 处

输入框自动具备该能力

36 个

页面复用同一渲染，投票卡片全站可见

0 张

业务表被改动，正文中只存一行文本标记

74 条

三语文案，键路径完全对齐

帖内投票

随手发起，不必新建活动

- **配置项：**单选或多选（可限定最多选 N 项）、匿名投票、投票后才可见结果、截止时间。
- **结果呈现：**进度条 + 票数 + 百分比；非匿名投票在选项下显示投票人头像。
- **可改票、可撤票、可提前结束；**创建者与管理员在无人投票前可整体修改题目与选项。
- **未登录也能看到题目与公开结果，**点击投票时引导登录并返回原页面。
- 一条内容最多可放 10 个投票，适合"多个议题一次收集"。

个人表情包

让技术讨论不必一直板着脸

- **个人表情库：**底部分「最近 / 全部 / 收藏」三档，支持上传图片与 GIF 动图，动图原样保存不转静态。
- **一键收藏他人的表情：**看到别人发的表情，点开大图即可「添加到表情包」；鼠标右键也可在光标处直接添加。
- **悬停预览可直接收藏或删除；**触屏长按同样可用。
- **每人最多 500 张，单张 10 MB。**

此处放：编辑器工具栏截图

建议截含 🇮🇹 投票与 😊 表情包按钮的工具栏

此处放：投票卡片截图

建议截正文中已渲染的投票（含进度条与投票人头像）

启示：把能力做在编辑器层而非单个页面，收益是非线性的 —— 一次投入，19 处输入同时可用，后续新增板块自动继承。

【能力现状】极客视频与随刷短视频：看得进去，也发得出来

长视频承担系统性分享，短视频承担高频传播，两者共用一套互动数据

随刷短视频

人人可发

- **竖屏随刷**：一屏一条、快速滑动不跳条；双击点赞、拖动进度、键盘切换、空格暂停。
- **发布流程**：拖入文件即自动读取时长与分辨率、抓取首帧作封面；文案可用 AI 润色后发布。
- **自动中英双语字幕**：发布后服务器在后台完成语音转写与翻译，播放时按钮在「中 / EN / 关」间切换并记住选择。
- **互动**：点赞、评论（抽屉式）、收藏进「稍后看」、分享链接。

极客视频

系统性分享

- **AI 看点摘要**：一句话钩子加数条关键看点，30 秒判断这一小时值不值得看。
- **就视频提问**：针对这条视频提问，回答只依据本视频的文字稿，没讲到会明确说明。
- **悬停预览**：鼠标停在卡片上播放专门的预览片段。
- **分类与标签筛选**，收藏进「稍后看」，评论与回复通知可深链回原处。
- **搬运必须署名**：上传时区分自创与搬运，搬运须填原始链接与原作者，播放页展示可点来源。

字幕生成流程

全程在内网完成，不依赖任何云服务

① 抽音轨

16 kHz 单声道

② 本机转写

服务器本地语音识别

③ 分批翻译

内网模型逐批翻译

④ 播放切换

中 / EN / 关

翻译时若编号与原文对不上则整批放弃 —— 宁可只出原文字幕，也不出错轴字幕。

此处放：短视频随刷截图

建议截带字幕开关与右侧互动按钮的竖屏画面

其他

- **长短视频互通**：点赞、收藏、评论是同一套数据，短视频收藏后同样进入「稍后看」。
- **精选进首页**：管理员可将优质短视频设为精选，出现在首页与视频页的推荐位。
- **观看计数按人按天去重**，累计播放满 2 秒才计一次，热度排序更接近真实。
- **为什么滑得动**：信息流中只在当前条前后各两条挂载真实播放器 —— 每个播放器占用一个硬件解码器，移动端数量有限，全量挂载会直接黑屏。

启示：短视频把“技术分享”的发布门槛降到一条手机视频，这是目前唯一一个成员可以自主发布的媒体形态。

【能力现状】社区活动：从发布到提醒的完整链路

任何成员都可以发布活动，不必经过组织方

发布方

任何成员均可发起

- **基本信息**：标题、简介、正文、封面（可拖动取景，竖图不被裁切）。
- **分类**：四个大类（外部活动 / 内部活动 / 专家分享 / 研讨会）+ 十个主题标签（每场最多 3 个）。
- **形式与地点**：线上 / 线下 / 两者兼有；七个城市可选；会议链接**仅登录成员可见**。
- **讲师阵容**：可添加多位讲师，含姓名、职务、单位、头像、简介与链接，详情页以名片形式展示。
- **状态管理**：可取消（保留展示并加【已取消】标记）、可修改；管理员可置顶推荐。

参与方

找得到、记得住、不错过

- **时间按本地显示**：组织者按自己时区填一次，其他人看到自己所在地的时刻，并列显示原时区。
- **筛选与日历联动**：按时间、大类、主题、形式、城市筛选；右侧月历上有活动的日子带圆点，点某天列表即只留当天。
- **一键报名 = 订阅提醒**：开场前约 30 分钟自动发站内通知与邮件；取消报名即停止提醒。
- **加入个人日历**：Google 日历链接或下载 .ics 给 Outlook / Apple。
- **「我参加的」视图**，卡片带高亮边框与已参加标记；往期活动仍可回看，含讲师与内容。
- **相关活动推荐**：详情页底部推荐同类型或主题重叠的其他活动。

同一场活动在不同地区的显示

组织者只填一次

浏览者所在地	页面显示	说明
多伦多（组织者）	8 月 20 日 14:00	组织者按本地时间填写
北京	8 月 21 日 02:00	自动跨日，列表按浏览者本地日期分组
温哥华	8 月 20 日 11:00	并列显示"多伦多 14:00"，免去心算
全天活动	8 月 20 日 全天	不做换算，避免在别的时区变成前一天

此处放：活动日历截图

建议截左侧筛选 + 右侧月历圆点联动的画面

提醒由"网页轮询"与"服务器定时任务"两条路径共同触发，内网缺少统一调度设施，这是刻意
的双保险；两条路径同时开启也不会重复发送同一条提醒。

启示：一场讲座的价值取决于有多少该来的人知道 —— 全员可见的日历 + 自动提醒，把"通知"从组织者的负担变成系统能力。

【能力现状】平台底座：一个铃铛、一个搜索框、一块需求板

这些能力被所有板块共用，也是新增板块的接入基础

通知中心

全站消息汇入一处

- **覆盖范围**：视频与动态的评论回复、论坛回帖、知识库批注与笔记回复、Skill 下载申请与审批结果、活动开场提醒、全员公告。
- **点击直达**：不是跳到页面顶部，而是**滚动到那条具体回复并高亮**；若目标嵌在某个楼层里，该楼层会自动展开——即使它原本在第三页尚未加载。
- **自己定开关**：四类事件 × 站内信 / 邮件两个渠道，共八个开关，互不影响。
- 未读数红点显示，可一键全部已读。

全站检索

⌘K 唤起

- 任何页面按 ⌘K / Ctrl+K 唤起搜索面板，同时搜 11 类内容：Skill、合集包、知识库文档、讨论动态、论坛话题、视频、活动、投票、意见反馈、用户、分类与标签。
- 分组展示，上下键选择、回车进入全量结果页。
- 每类内容自带可见性过滤：未发布、已删除、私有内容不会出现在结果里。

意见反馈板

需求登记与进展公开

- 任何人都可以提功能建议或问题反馈，给别人的条目投票 +1，并在下面二级讨论。
- 条目带状态标签：**待处理** / **已计划** / **处理中** / **已完成** / **不采纳**，可按票数排序看什么最被需要。
- 让"下一步做什么"有公开依据，而不是少数人拍板。

公告与个人空间

- **公告**：管理员发布后所有成员通知中心即刻可见，首页常驻最新一条入口。
- **个人主页**：公开展示自己的 Skill、文档、动态、话题、书架与参与的活动。
- **私人工作台**：草稿、订阅更新提示、待处理的下载申请集中管理。
- **三语界面**：中 / 英 / 法即时切换，首次访问按浏览器语言自动选择。



首页——未登录时直接给出安装命令；登录后为今日新增、热门讨论、即将举行的活动与新上架文档（演示数据）。

启示：这一层决定新增板块的接入成本——加第七个板块时，账号、通知、评论、检索、权限均无需重建。

【能力现状】账号、权限与隐私：实名之上的分寸感

实名让协作更高效，也要求平台对"谁能看到什么"给出明确边界

登录与身份

成员侧

- **W3 一键登录**：跳转 UniPortal 后即为注册用户，无需填表；此前用邮箱注册过的人会自动合并为同一账号，不会变成两个人。
- **部门自动挂载**：登录时按工号匹配员工名单，名字旁自动出现「XX 部 · XX 所」标签，本人无需填写也无法自行修改。
- **两种登录方式并存**：公网部署为邮箱密码，内网增加 W3 通道。

隐私控制

成员自己决定

- **隐私账号开关**：开启后，其他成员看到的只有昵称与头像，部门、研究所与工号均不显示。
- **个人主页分板块开关**：Skill、知识库、动态、评论、书架、活动六个板块各自可隐藏，隐藏后他人连数据都取不到；本人仍可见，标注"仅自己可见"。
- **内容三档可见性**：公开、受限（可被搜到、下载需批准）、私有（对他人不可见）。

管理后台

13 个板块 / 17 个页面

- **用户管理**：管理员、允许发布、允许 Remix、允许使用命令行、每日下载上限，逐项开关即时生效。
- **员工名单**：支持粘贴文本 / CSV / XLSX 三种导入，逐行显示失败原因，单次上限 2 万行；可一键同步部门信息到账号。
- **内容管理**：Skill、视频、短视频、知识库、讨论、投票、活动、公告、分类各有管理入口。
- **操作日志**：37 种管理动作全部留痕，可按动作、对象、管理员检索。
- **自助诊断**：网络出口、邮件、模型连通性三项即时检测。

此处放：管理后台截图

建议截「用户管理」或「员工名单导入」页面

隐私不是前端隐藏，而是**服务端裁剪**：隐私账号的部门信息在服务端就被移除，数据不会发送到浏览器。员工名单**只按工号匹配**，不按用户名——公网为开放注册，按用户名匹配等同于开放身份冒领。

启示：实名社区的信任来自边界清晰——该露的自动露（部门、产出），不想露的能彻底关掉（隐私开关）。

【工程规模】8.5 万行自研代码，90 天，104 次提交

2026-05-22 第一次提交，2026-08-19 最近一次，其间 28 个有提交的活跃日，单一作者；累计新增 15.2 万行、删除 1.3 万行。

85,190

自研代码行数
(TSX + TS + JS / CSS，不含依赖与文档)

72

数据表
(160 个索引与唯一约束 · 40 个枚举)

151


服务接口
(另有 72 个服务端渲染页面)

290

单元测试用例
(26 个测试文件，1.17 秒跑完)

104

次提交 / 90 天
(月均约 35 次)



代码构成		git ls-files 逐类统计
页面与组件 TSX	47,539 行 / 283 个文件	
服务端与库 TS	36,818 行 / 322 个文件	
数据模型 Prisma	1,989 行 / 72 个模型 · 40 个枚举	
数据库迁移 SQL	2,300 行 / 34 次结构演进，可按序重放	
测试代码	2,927 行 / 26 个文件，占业务代码约 3.4%	
三语文案	2,556 个键 × 3 种语言，键路径差异为 0	
第三方依赖	45 个运行时 + 19 个开发依赖	
提交作者	1 人 —— 104 次提交全部来自同一作者	
最大单文件	ReaderShell.tsx 1,604 行 (阅读器主控)	

测试是 290 个用例、2,927 行，全部不连数据库、不连网络，一条命令 1.17 秒跑完一轮回归 —— 因此每次改动都跑得起。

【发展路径】当前瓶颈不在功能供给，而在参与转化

按参与漏斗逐层拆解，两处断点决定了社区能否形成规模

参与漏斗

宽度为示意，实际数值随第一批上线一并出基线

目标人群 —— 研发与技术相关岗位全员



登录过 —— 已有账号，进过站点



近期访问过 —— 30 天内有浏览行为

▼ 断点一：从"看到"到"发"

发布过内容 —— 发过至少一条

▼ 断点二：从"发一次"到"持续发"

持续贡献 —— 连续四周有产出

断点一：从"看到"到"发"

三个原因

- 看到的是内容列表，不是人。不知道谁在做什么，缺少互动起点。
- 第一条门槛高。担心写得不好、不确定发在哪、排版耗时。
- 缺少发布场景。只有"正式内容"的位置，没有"日常记录"的位置。

断点二：从"一次"到"持续"

两个原因

- 发布后无回响。零回复即等同于"第一次就是最后一次"。
- 贡献无出口。点赞与下载量只是流水，既不进入个人履历，也不带来实际权益。

由此得出的判断：继续扩展功能无法改善上述五项原因中的任何一项。本轮建设应集中于机制 —— 让人可见、让发布容易、让留存有理由。三条发展路线由此展开。

判断：功能供给已经充分，参与转化是唯一瓶颈。本轮不再新增板块，全部投入用于打通两处断点。

【发展路径】三条路线的定位与比较

横轴为见效速度，纵轴为可持续性；圈选位置代表各路线的典型表现



对比维度	A · 真人社区（建议主线）	B · 专家专栏	C · 资源挂钩
内容供给方	全员，日常记录亦为内容，供给面最宽	少数专家，约稿制，供给面最窄	被动产生，为获取额度而发布
运营投入	中：3—5 名种子活跃者 + 每周一次精选	高：需编辑、约稿与排期，断更即失效	低：规则自动执行，但需额度池授权
主要风险	内容参差；实名环境下首发顾虑	与既有严肃社区同质化，且缺少作者储备	为获取额度而灌水，并将分享行为交易化
建议定位	★ 作为主线	作为 A 内的一个栏目	作为 A 的放大器

结论：以 A 为主线，B 降级为栏目，C 定位为放大器。三线并行将导致资源分散且互相稀释。

【发展路径】主线落地：三阶段推进，顺序不可调换

每一阶段均包含建设内容、运营动作与验收指标三部分

1 让人可见

约 4 周 · 见第 19 – 21 页

建设内容

- 关注与动态流、@ 提及
- 个人名片与本周红人
- 统一话题（跨板块）

■ **不能省的原因：**后续的红人评定、话题聚合、精选分发都以关注关系为承载，缺此层则各功能各建一套。

运营动作

管理员与种子活跃者先行入驻，完善个人名片，形成“看得见人”的初始密度。

验收：关注关系数 · 名片完善率

2 让发布容易

约 8 周 · 见第 22 – 23 页

建设内容

- 一键发日常 + AI 顺稿
- 新人首帖引导与欢迎
- 一页速递与每周精选

■ **不能提前的原因：**无人可见时降低发布门槛，只会得到无人回应的内容，反而加速流失。

运营动作

新人首帖 24 小时内必有回应；每两周组织一个话题；每周一次精选与红人评定。

验收：首次发帖转化率 · 零回复率

3 让留存有理由

按季度 · 见第 24 – 27 页

建设内容

- 问答终态与 AI 值班员
- 贡献激励与 AI 额度挂钩
- 专家专栏、语义检索地基

■ **不能提前的原因：**计分阈值需以第一阶段的真实行为数据校准，否则等级与称号的授予标准无从确定。

运营动作

季度评优与荣誉授予；专栏约稿排期；额度发放规则公示与自查页。

验收：周活跃发布人数 · 跨部门互动比例

启示：在“人尚不可见”的阶段投入激励，等同于向空场发放奖品；三阶段的先后关系不可调换。

【发展路径】一主两辅的组合方式

专栏与资源激励均不独立立项，而是挂接在主线之上

主线 A · 真人社区 关注与动态流 · 个人名片与红人 · 统一话题 · 一键发日常 · 新人引导 · 一页速递与每周精选 —— 目标：让每个人愿意发出第一条，并因此认识同事



辅线 B · 专家专栏

作为栏目挂接

- 形态：社区内的一个「专栏」标签与首页固定位置，不建独立站点。
- 供给：约稿与自荐并行，管理员择优挂精选；有稿即发，无稿不塌 —— 这是与独立立项的本质差别。
- 沉淀：专栏文章自动进入知识库，可被检索、可被 AI 引用，不止是一篇帖子。
- 作者回报：作者认领与署名、被引用计数、荣誉称号 —— 对研发人群优于稿酬。
- 差异化：不与既有严肃社区比权威性，而比与当前工作的贴近度：内网模型如何使用、我们自己的问题如何解决。



辅线 C · AI 资源激励

作为放大器挂接

- 只奖励被他人使用的贡献 —— 回答被采纳、Skill 被安装、文档被收藏、收到致谢；**发布条数不计分**。此条决定了它不会演变为灌水机制。
- 额度为增量而非门槛 —— 基础额度对全员一致，贡献换取的是更高上限，新成员不会遭遇限制。
- 发放全自动，按等级与成就即时生效，无需人工审批，运营成本接近于零。
- 需要一次授权：额度池归属与季度总量，这是本轮唯一需要外部批准的资源事项。
- 止损机制：一旦出现为获取额度而灌水的迹象，先降权后停发，规则全程公开可查。

结论：A 是人，B 是内容，C 是燃料。燃料投向尚无人气的场地，只会消耗预算而不产生资产。

【建设规划】十二项功能的定位矩阵

纵向为服务阶段，横向为工作量；标红为第一批，均无外部依赖

	小（1－2 周）	中（3－6 周）	大（需外部支撑）
让人可 第一阶 见 段	① 关注与动态流 + @提及 把"内容列表"变成"人的现场"	③ 统一话题 合并三套割裂的分类体系	—
让发布 第二 容易 阶段	② 个人名片与本周红人 让发得好的人被看见 ④ 一键发日常 + AI 顺稿 把首发成本压到一分钟 ⑤ 新人首帖引导 承诺 24 小时内有人回应	⑥ 一页速递与每周精选 固定分发位，解决"发了就沉"	—
让留存 第三 有理由 阶段	⑦ 问答终态（采纳） 让讨论有终点 ⑩ 专家专栏 高质量长文的固定位置	⑧ AI 值班员 24 小时内必有首答 ⑨ 贡献激励 + AI 额度 贡献转化为实际权益 ⑫ 双周挑战赛 激活长期潜水人群	⑪ 语义检索地基 需内网加载向量模型 ⑪ MCP 知识出口 需前两批内容沉淀

第一批（六项）	3－5 周，可立即启动	第二批（五项）	1－2 个月	第三批（两项）	后续季度
■ 关注与动态流 + @ 提及 · 个人名片与本周红人 · 统一话题 ■ 一键发日常 + AI 顺稿 · 新人首帖引导 · 一页速递与每周精选 ■ 共同目标：形成"发布即有回应"的最小闭环，六项互为前提。		■ 问答终态 · AI 值班员 · 贡献激励与 AI 额度 · 专家专栏 · 语义检索地基 ■ 前置条件：需第一批积累的真实行为数据作为计分依据；其中两项受向量模型排期约束。		■ MCP 知识出口 · 双周挑战赛 ■ 前置条件：依赖前两批沉淀的已验证内容与运营节奏；社区尚无内容时出口无价值。	

提示。
启示：第一批六项是一个整体 —— 拆开交付会让"发布即有回应"的闭环不成立，收益并非线性叠加。

【投入与效果】交付节奏：三批推进，关键路径为算力排期

横轴为周次；第一批与算力申请并行启动，互不阻塞



第一批验收 上线四周后回答三个问题 ■ 有多少人发出了第一条内容 ■ 有多少条内容获得三个以上的互动 ■ 速递带来多少次回站点击 ■ 数据不达标即调整机制，不追加功能。	关键路径 决定第二批开工时间 ■ 向量模型的排期是唯一不可控项，因此与第一批同时启动申请。 ■ 若排期滞后：AI 值班员按单板块降级版本先行，语义检索顺延。 ■ 贡献激励需第一批积累四周以上的真实行为数据方可校准阈值。	本轮不做事： 不新增板块、不做私信、不设全站总分排行榜、不做等级降级。功能供给已经充分，本轮全部投入用于机制建设。
--	---	---

结论：三批的先后关系由依赖决定，不可调换；其中唯一的外部关键路径是算力排期，建议本周启动。

【投入与效果】度量口径：以"周活跃发布人数"为北极星

访问量波动快且不可持续，只有持续产出才构成社区资产

指标	口径	1 个月	3 个月	6 个月
★ 周活跃发布人数	本周发布过动态 / 话题 / 回复 / 短视频任一项的人数	出基线	基线的 3 倍	基线的 6 倍
首次发布转化率	登录过的人员中，发布过至少一条内容的比例	出基线	≥ 25%	≥ 40%
内容平均互动人数	单条内容平均获得反应或评论的不同人数（衡量"发布后是否有人回应"）	出基线	≥ 3	≥ 5
跨部门互动比例	互动双方不属于同一部门的比例（衡量"是否真正认识了其他团队"）	出基线	≥ 30%	≥ 40%
零回复率	发布 24 小时内无任何回应的内容占比（越低越好，直接对应"首次即末次"）	出基线	≤ 20%	≤ 10%
速递回站率	由速递进入站内的点击人数 / 发送人数（内网邮件无可信打开率，只统计点击）	—	≥ 20%	≥ 25%

基线获取方式：上述指标可用管理后台现有数据回溯最近 30 天直接计算，会前出数并写入纪要冻结；种子活跃者带来的增量单独标注，不计入分子分母，否则目标失去意义。

难以量化但更为关键的三项：新成员第一天即可判断"该方向应找谁"；同事之间能够互相识别；有人因在社区中被看见而持续产出。三者出现后，量化指标才会随之改善。

原则：度量口径先于功能确定。无基线则三个月后无法判断本轮投入的实际效果。

【投入与效果】需要决策的四项事宜

为什么是现在：平台建设成本已经投入，机制层若不补齐，该部分投入将随参与度下滑而沉没

序	事项	用途	不予落实的影响
1	AI 额度池的授权 额度归属与季度总量	将贡献与 AI 资源挂钩：被采纳、被安装、被致谢者自动加发额度，全流程自动执行、无需审批	激励仅余荣誉一层。 该项是我方独有且见效最快的手段 ，闲置即为浪费
2	向量模型的算力排期 约 0.5—1B，单卡 8—16 GB 显存	语义检索地基：全站检索、发帖查重、跨类型推荐、AI 值班员的全站检索	第二批半数功能降级实现； 等待时长不由我方决定，建议本周启动申请
3	运营配置 0.3 — 0.5 人力 + 3 — 5 名种子活跃者	每周一次精选与红人评定（约 10 分钟）· 每两周组织一个话题 · 新人首帖 24 小时内回应 · 种子活跃者首月每人每周两条	机制设计已尽量降低运营强度，但冷启动阶段无法完全自动化。 这是最大的单点风险，也是成本最低的一项
4	一至两个试点部门 主管带头发布	首月在两个部门内跑通"发布即有回应"，形成可复制的示范后再向外推广	社区类产品的成败取决于前 30 天，冷启动期缺少示范，后续补救成本显著更高

总投入：开发由现有 1 人承担 —— 第一批 3—5 周、第二批 6—8 周，**不新增编制**，代价为同期其他任务顺延。除额度池外无新增预算。

预计收益：重复建设的 Skill 转为一次上传多次安装；长文档由一人读完、全员可问；找人方式由"群内询问"转为"检索定位"。按首年 60 个跨部门 Skill、200 条沉淀问答估算，量级在千人时。

止损线：第一批上线四周后，若发布过首条内容的人数低于 __、零回复率仍高于 __%，则停留在第一批不再追加投入，已上线功能维持运行。

四项之中最紧迫的是第 2 项：**算力排期的等待时长不由我方决定，越早启动，第二批越不易被阻塞。**

Thank you.

六大板块已建成并在内网稳定运行。本轮不再扩展功能，全部投入用于一件事 —— 让每一位同事都愿意在这里发出第一条内容。

欢迎现场提问；会后可获取第一批的详细实施方案。

