

算子融合与 INT4 量化的联合评测

演示材料 · 数据为构造样例，不代表任何真实产品结论

- 评测目标与范围
- 基线与硬件配置
- 单点改动的收益拆解
- 组合后的相互作用
- 结论与下一步

2 基线与硬件配置

项目	取值	说明
模型规模	7B / 稠密	权重 FP16 基线
上下文	4096	输入 1024 / 输出 128
批处理	连续批处理	最大并发 32
量化	INT4 (权重)	激活保持 FP16
算子融合	Attention + MLP	融合后减少一次显存往返
重复次数	5 轮取中位数	丢弃首轮预热

所有数字都是为了演示排版而构造的，请勿引用。

5 结论与下一步

两项改动单独都有收益，叠加后并不是简单相加：

显存带宽先于算力成为瓶颈，融合的收益随批大小衰减。

尾延迟（P99）对批大小比吞吐敏感得多，

把批大小当成唯一旋钮会先撞上延迟预算。

下一步：把逐阶段计时接入常态化回归，

让每次内核改动都能落在同一张基线上比较。

遗留问题

- 低批场景下融合内核的收益尚未稳定复现
- 量化误差在长上下文下的累积仍缺少长跑数据